

FET312 DERİN ÖĞRENME FINAL SUNUMU

Derin Öğrenme ile Trafik İşareti Tanıma Sistemi (GTSRB)

Hazırlayanlar: Ramazan Bozkurt (22040301027) & Utku (22040301043)

https://github.com/RamazanBozkurrtt/DevTeam177_GTSRB-Traffic-Sign-Classification-CNN-Final | YouTube Showcase

PROBLEMIN AÇIKLAMASI



Kritik Risk Analizi

Otonom sürüste tabelaların yanlış tanınması hayatı tehlike yaratır. %98+ başarılı bir sınıflandırıcı güvenliğin temelidir.



Dış Faktörler

Düşük çözünürlük, yağmur, sis ve hareket bulanıklığı (motion blur) modeller üzerindeki en büyük zorluklardır.

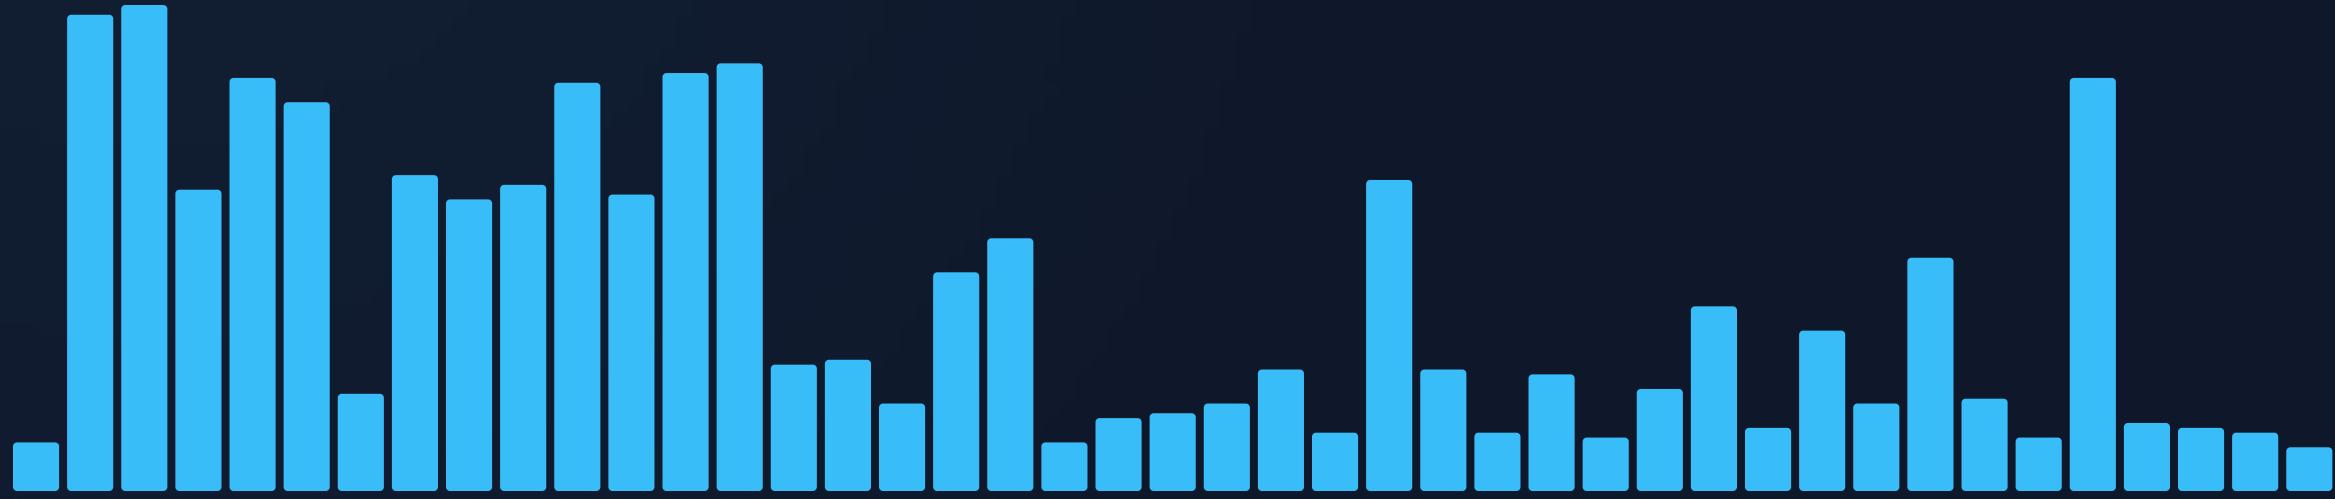


VERI SETİ (GTSRB) SPESİFIKASYONLARI



- ➊ **Kapsam:** 51.839 adet .ppm formatlı görsel.
- ➋ **Boyut:** 463 MB veri hacmi.
- ➌ **Boyutlandırma:** Değişken orijinal boyutlar (15x15 - 250x250) tüm modellerde **64x64** pikseli kare forma normalize edildi.
- ➍ **Etiketleme:** 43 farklı trafik levhası kategorisi.

SINIF DAĞILIMI VE DENGESIZLIK



Sınıf 0 Sınıf Dağılım Analizi (support değerleri 45 ile 750 arası değişkenlik gösterir) Sınıf 42

Strateji: Veri setindeki dengesizliği yönetmek için **Stratified Split** yapıldı ve başarı değerlendirmesinde sadece Accuracy değil, **Macro-F1 Score** temel alındı.

KULLANILAN MODERN EĞİTİM TEKNİKLERİ



Data Augmentation

RandomRotation (15°), ColorJitter (parlaklık) ve perspektif değişimleri ile veri sentetik olarak zenginleştirildi.



Batch Normalization

Eğitimi stabilize etmek, öğrenme hızını artırmak ve gradyan patlamalarını önlemek için tüm katmanlarda kullanıldı.



Regularization

Overfitting'i engellemek için %30-%50 oranlarında Dropout uygulandı ve ağırlıklar normalize edildi.



Veri Sızıntı Engelleme : GroupShuffleSplit

Aynı trafik levhasının ardışık video karelerinin biri eğitimde diğerini doğrulamada olursa model ezberleme yapar. Bunu engellemek için track_id üzerinden ayrıştırma yaparak aynı fiziksel levhanın tüm karelerinin ya sadece eğitimde ya da sadece doğrulamada olması sağlanmıştır.



Veri Seti Sarmalayıcı

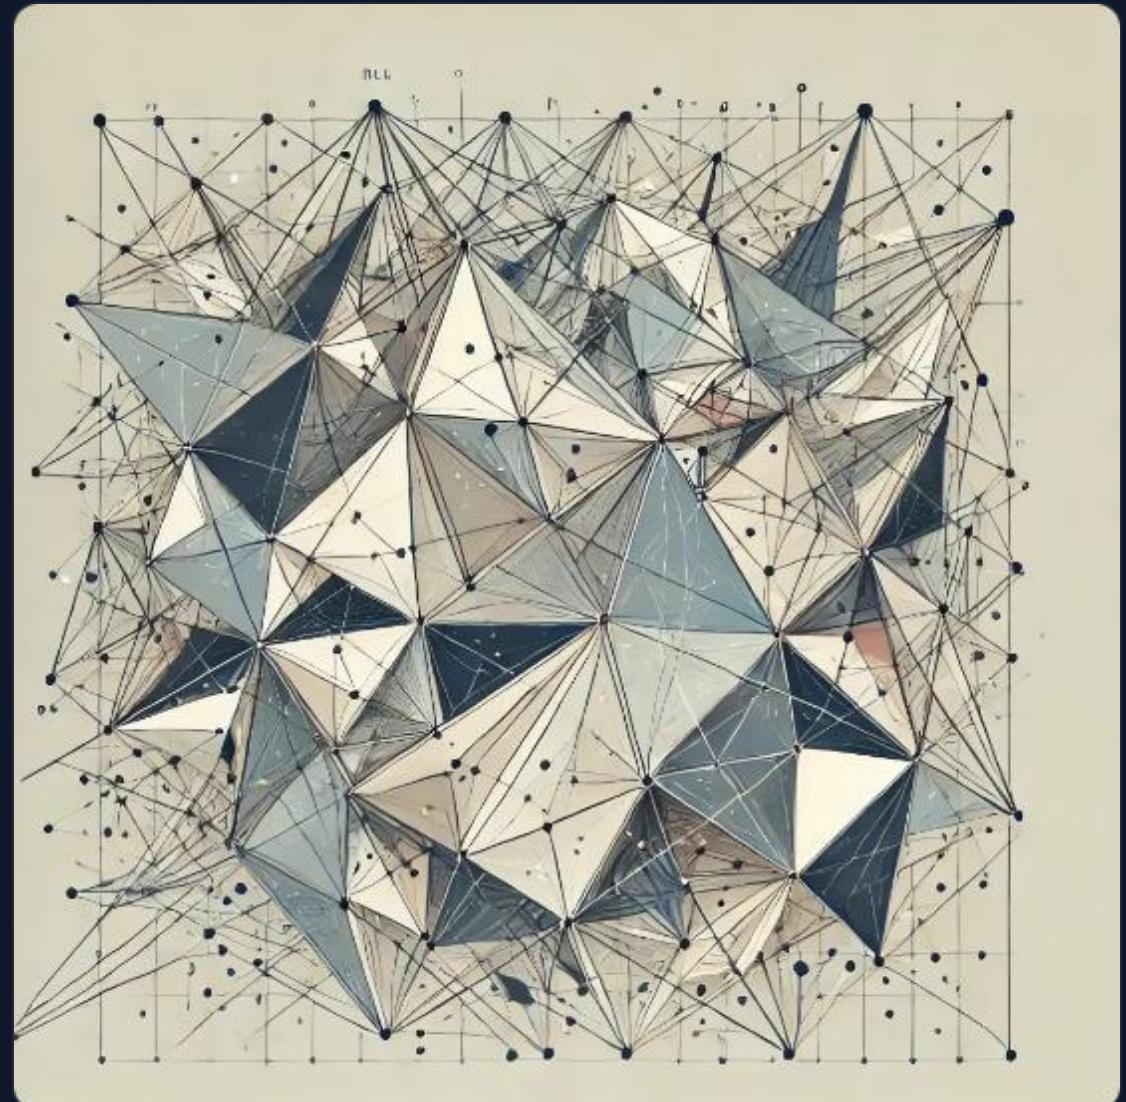
Efficient-B0 ve GoogleNet modelleri eğitilirken Torchvision transformasyonlarının Hata vermesin engellemek için Custom Dataset Wrapper kullanıldı.

DÜRÜST BÖLME STRATEJİSİ (GROUP-BASED SPLIT)

Track ID Tabanlı Bölme

GTSRB veri setinde aynı tabelanın ardışık 30 karesi bulunur.
Rastgele bölme yapılrsa, benzer kareler hem eğitim hem test
setine düşerek **overfitting sızıntısına** neden olur.

Bizim Yöntemimiz: Her tabela grubunu (Track) bir bütün olarak
ayırarak modelin **hic görmediği fiziksel tabelalar** üzerinde test
edilmesini sağladık.



EFFICIENTNET-BO MIMARI DETAYLARI



Compound Scaling Avantajı

EfficientNet, ağın derinliğini, genişliğini ve çözünürlüğünü dengeli bir şekilde ölçeklendirerek maksimum verimlilik sağlar.

- **Parametre Sayısı:** ~5.3 Milyon (Hafif ve Hızlı)
- **Optimizasyon:** Batch Normalization Entegrasyonu
- **Öne Çıkan Özellik:** Compound Scaling verimliliği

GENEL MODEL KARŞILAŞTIRMA RAPORU

Model Mimarisi	Mimari Türü	Parametre Sayısı	Test Accuracy	F1-Score (Macro)	Öne Çıkan Özellik
DenseNet-121	Dense (Yoğun)	~8M	%98.58	0.9885	Feature Reuse
ResNet-18	Residual (Artık)	~11.7M	%97.70	0.972	Skip Connections
GoogleNet	Inception(Derin Evrişimli Sinir Ağı)	~6.8M	%96.36	0.9350	Inception Module(Paralel Evrişim Yapısı)
EfficientNet-B0	Compound Scaling	~5.3M	%95.71	0.8845	Maksimum Verimlilik

EfficientNet-B0 yüksek doğruluk sunsa da, 5.3M parametre ile otonom araç donanımları için verimsiz kalmaktadır.

EFFICIENTNET-BO: SINIF BAZLI PERFORMANS (0-21)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
0	0.00	0.00	0.00	0	11	0.947	1.000	0.972	270
1	0.988	0.997	0.993	360	12	1.000	0.944	0.971	270
2	1.000	0.985	0.992	420	13	1.000	0.998	0.999	570
3	0.991	0.995	0.993	240	14	1.000	1.000	1.000	150
4	0.997	1.000	0.998	480	15	1.000	1.000	1.000	120
5	0.983	0.993	0.988	300	16	1.000	0.991	0.995	120
6	1.000	1.000	1.000	120	17	1.000	1.000	1.000	180
7	1.000	0.996	0.998	270	18	0.976	1.000	0.988	330
8	1.000	0.995	0.997	210	19	0.00	0.00	0.00	0
9	0.996	1.000	0.998	300	20	0.974	0.625	0.761	120
10	1.000	1.000	1.000	450	21	0.697	1.000	0.821	30

EFFICIENTNET-BO: SINIF BAZLI PERFORMANS (22-42)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
22	1.000	1.000	1.000	60	32	1.000	1.000	1.000	30
23	1.000	0.844	0.915	90	33	0.742	0.866	0.800	90
24	1.000	1.000	1.000	90	34	0.787	0.700	0.741	90
25	1.000	1.000	1.000	360	35	0.993	1.000	0.996	150
26	1.000	0.911	0.953	90	36	0.736	1.000	0.848	120
27	1.000	1.000	1.000	120	37	1.000	0.283	0.441	60
28	1.000	0.988	0.994	90	38	0.703	0.997	0.825	360
29	0.967	1.000	0.983	30	39	0.00	0.00	0.00	150
30	1.000	1.000	1.000	150	40	1.000	0.922	0.959	90
31	1.000	1.000	1.000	270	41	1.000	1.000	1.000	30
Sum	Micro Avg Accuracy: 0.9571				42	1.000	1.000	1.000	30

GoogLeNet: SINIF BAZLI PERFORMANS (0-21)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
0	0.00	0.00	0.00	0.00	11	0.981	1.000	0.990	270
1	0.991	0.991	0.991	360	12	1.000	0.985	0.992	270
2	0.985	1.000	0.992	420	13	1.000	0.996	0.998	570
3	0.991	1.000	0.995	240	14	1.000	1.000	1.000	150
4	0.997	0.997	0.997	480	15	1.000	1.000	1.000	120
5	0.996	1.000	0.998	300	16	1.000	0.975	0.987	120
6	1.000	1.000	1.000	120	17	1.000	1.000	1.000	180
7	1.000	1.000	1.000	270	18	1.000	1.000	1.000	330
8	1.000	0.995	0.997	210	19	0.00	0.00	0.00	0.00
9	0.998	0.970	0.979	300	20	0.978	0.766	0.859	120
10	0.991	0.997	0.994	450	21	1.000	1.000	1.000	30

GoogLeNet: SINIF BAZLI PERFORMANS (22-42)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
22	1.000	1.000	1.000	60	31	1.000	1.000	1.000	270
23	1.000	0.944	0.971	90	32	1.000	1.000	1.000	30
24	1.000	1.000	1.000	90	33	0.671	0.977	0.796	90
25	0.997	1.000	0.998	360	34	0.959	0.522	0.676	90
26	1.000	0.988	0.994	90	35	1.000	1.000	1.000	150
27	1.000	0.991	0.995	120	36	0.705	1.000	0.827	120
28	0.976	0.933	0.954	90	37	1.000	0.166	0.285	60
29	0.789	1.000	0.882	30	38	0.707	1.000	0.828	360
30	1.000	0.993	0.996	150	39	1.000	1.000	1.000	150
Sum	Macro Avg F1: 0.8836				40	1.000	1.000	1.000	90
					41	1.000	1.000	1.000	30

DENSENET-121: SINIF BAZLI PERFORMANS (0-19)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
0	0.968	1.000	0.984	60	9	0.992	0.994	0.993	480
1	0.992	1.000	0.996	720	10	1.000	0.998	0.999	660
2	0.986	0.999	0.992	750	11	0.933	0.990	0.961	420
3	0.996	0.984	0.990	450	12	0.980	0.993	0.986	690
4	1.000	0.983	0.992	660	13	0.969	0.999	0.984	720
5	0.989	0.984	0.986	630	14	0.993	1.000	0.996	270
6	1.000	0.947	0.973	150	15	1.000	0.990	0.995	210
7	0.996	0.996	0.996	450	16	1.000	1.000	1.000	150
8	0.985	0.998	0.991	450	17	1.000	0.944	0.971	360
					18	1.000	0.990	0.995	390
					19	1.000	1.000	1.000	60

DENSENET-121: SINIF BAZLI PERFORMANS (20-42)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
20	0.989	1.000	0.994	90	31	0.993	0.993	0.993	270
21	0.988	0.944	0.966	90	32	1.000	0.900	0.947	60
22	1.000	0.917	0.957	120	33	1.000	1.000	1.000	210
23	0.974	1.000	0.987	150	34	1.000	1.000	1.000	120
24	0.978	1.000	0.989	90	35	0.992	0.987	0.990	390
25	0.947	0.998	0.972	480	36	0.984	1.000	0.992	120
26	0.968	1.000	0.984	180	37	0.952	0.983	0.967	60
27	1.000	0.550	0.710	60	38	0.999	0.986	0.992	690
28	0.987	1.000	0.993	150	39	0.978	1.000	0.989	90
29	0.978	1.000	0.989	90	40	1.000	0.967	0.983	90
30	0.968	0.807	0.880	150	41	0.952	1.000	0.976	60
					42	0.957	1.000	0.978	90

Final Accuracy: 0.9858

RESNET-18: SINIF BAZLI PERFORMANS (0-21)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
0	1.000	0.967	0.983	60	11	0.969	0.960	0.964	420
1	0.990	0.992	0.991	720	12	0.993	0.970	0.981	690
2	0.961	0.988	0.974	750	13	0.969	0.997	0.983	720
3	0.963	0.987	0.975	450	14	1.000	1.000	1.000	270
4	0.994	0.979	0.986	660	15	1.000	0.995	0.998	210
5	0.987	0.965	0.976	630	16	1.000	0.993	0.997	150
6	0.992	0.813	0.894	150	17	1.000	0.942	0.970	360
7	0.989	0.973	0.981	450	18	0.997	0.946	0.971	390
8	0.867	0.998	0.928	450	19	1.000	1.000	1.000	60
9	0.994	0.988	0.991	480	20	0.928	1.000	0.963	90
10	1.000	0.997	0.998	660	21	0.873	0.989	0.927	90

RESNET-18: SINIF BAZLI PERFORMANS (22-42)

ID	Precision	Recall	F1-Score	Supp.	ID	Precision	Recall	F1-Score	Supp.
22	0.990	0.833	0.905	120	34	1.000	1.000	1.000	120
23	0.974	1.000	0.987	150	35	0.992	0.987	0.990	390
24	0.988	0.933	0.960	90	36	0.984	1.000	0.992	120
25	0.961	0.981	0.971	480	37	1.000	0.900	0.947	60
26	0.967	0.989	0.978	180	38	0.996	0.988	0.992	690
27	0.984	1.000	0.992	60	39	0.989	0.989	0.989	90
28	0.955	1.000	0.977	150	40	0.988	0.911	0.948	90
29	0.891	1.000	0.942	90	41	1.000	1.000	1.000	60
30	0.882	0.800	0.839	150	42	0.918	0.989	0.952	90
31	0.996	0.996	0.996	270	Final Accuracy: 0.9770				
32	1.000	1.000	1.000	60					
33	1.000	0.995	0.998	210					

ResNet-18, **residual connections** sayesinde en derin modeller arasında en yüksek doğruluğa sahip mimarı olarak öne çıkmaktadır.

KRİTİK BULGULAR VE TEKNİK ANALİZ



Dengesizlik Etkisi

Support sayısı 45 olan nadir sınıflar (Sınıf 0, 19, 42 vb.) GoogleNet ve ResNet gibi modeller tarafından başarıyla öğrenilirken, EfficientNet bu sınıflarda daha fazla veri artırmaya ihtiyaç duymuştur.



Hız vs Doğruluk

EfficientNet-B0 otonom araçlar için en "verimli" modeldir (5.3M parametre), ancak kritik güvenlik uygulamalarında DenseNet-121 %98+ başarımı tercih edilmelidir



Feature Reuse

DenseNet'in özellik tekrar kullanımı sayesinde düşük parametre sayısına rağmen yüksek recall değerleri elde edilmiştir.



ŞAMPIYON MODEL: DenseNet-121

Neden En İyisi?

- ✓ **Feature Reuse:** Her katman önceki tüm katmanların çıktılarını görür. Trafik levhalarında kenar + renk + şekil bilgisini daha iyi öğrenir. Bu bilgiler kaybolmadan derine taşınır
- ✓ **Parametre Verimliliği:** Daha az parametre ile ResNet-18'i geçti. Overfitting riski daha düşük

Final Değerlendirme : DenseNet-121 mimarisi, yoğun bağlantı yapısı sayesinde özellik tekrar kullanımını artırarak küçük ve benzer trafik levhaları arasındaki ayırt edici bilgileri daha iyi korumuştur. Bu durum, özellikle zor sınıflarda daha dengeli performans sağlayarak %98.58 test doğruluğu ile en iyi sonucu vermesine neden olmuştur.

KULLANILAN KAYNAKLAR VE VERI PORTALLARI

- 🔗 Veri Seti: benchmark.ini.rub.de/gtsrb_news.html
- 🔗 Yayın Arşivi: [sid.erda.dk/public/archives/...](http://sid.erda.dk/public/archives/)
- 🔗 ImageNet Modelleri: pytorch.org/vision/stable/models.html
- 🔗 DenseNet Makalesi: <https://arxiv.org/abs/1608.06993>
- 🔗 GoogleNet Makalesi: <https://arxiv.org/abs/1409.4842>

IMAGE SOURCES



https://miro.medium.com/0*bFEWUG9VCRqep9SZ

Source: [medium.com](#)



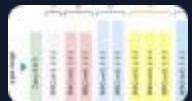
https://www.mdpi.com/information/information-15-00621/article_deploy/html/images/information-15-00621-g001.png

Source: [www.mdpi.com](#)



<https://thegradient.pub/content/images/2024/11/DALL-E-2024-11-15-15.40.52---Create-an-abstract-image-that-illustrates-how-ReLU-based-neural-networks-shatter-input-space-into-numerous-polygonal-regions--each-behaving-like-a-lin.webp>

Source: [thegradient.pub](#)



<https://blog.roboflow.com/content/images/2024/04/image-1081.webp>

Source: [blog.roboflow.com](#)